

Bitácora de Decisiones del Proyecto Final de Machine Learning II

Pronóstico de Ocupación por Barrio en Barcelona

Estudiantes:

Atencio Jose 9-710-310
Bosques Karina 8-942-2155
Campos Joshua · 8-890-2410

Profesor: Juan Montenegro

Decisión 01 – (10-Sep-2026): Exclusión de alojamientos sin información geográfica

Al comparar los archivos calendar y listings nos encontramos con 113 alojamientos sin correspondencia, equivalentes a 41,245 registros (0.7335% del total). Como no era posible asociarlos con un barrio y el análisis depende de esa ubicación, se decidió excluirlos.

Decisión 02 – (11-Sep-2026): Selección de la variable geográfica

Se revisaron neighbourhood, neighbourhood_cleansed y neighbourhood_group_cleansed. La primera se descartó porque tenía valores nulos en el 100% de los registros. Se seleccionó neighbourhood_cleansed para representar los barrios, ya que estaba completa y permitía trabajar con 69 barrios. La variable neighbourhood_group_cleansed se conservó como nivel geográfico superior para el análisis posterior por distritos.

Decisión 03 – (12-Sep-2026): Análisis de representatividad de los barrios

Antes de modelar se revisó cuántos alojamientos tenía cada barrio. La distribución resultó muy desigual: algunos barrios tenían un solo listing, mientras que el máximo alcanzaba 2,145 y la mediana era 72. Se probaron distintos mínimos de representación y se decidió trabajar con barrios que tuvieran al menos 10 listings. Con este criterio quedaron 58 de los 69 barrios y se conservó aproximadamente el 99.71% de los alojamientos, evitando que zonas con muy pocos registros tuvieran un peso desproporcionado en el análisis.

Decisión 04 – (12-Sep-2026): Construcción de la variable objetivo

Se definió **occupancy_rate** como la proporción de alojamientos marcados como no disponibles para cada barrio y fecha. Los registros disponibles se representaron con 0 y los no disponibles con 1, para luego calcular la proporción por barrio. Esta variable se utiliza como una estimación

de ocupación y no como una confirmación de reservas, porque una fecha también puede estar bloqueada por decisión del anfitrión.

Decisión 05 – (12-Sep-2026): Selección de MAE como métrica principal

Se eligió **MAE (Mean Absolute Error)** como métrica principal antes de comparar los modelos. Su interpretación es directa para el problema, indica cuánto se alejan, en promedio, las predicciones de la ocupación estimada real, sin que errores positivos y negativos se cancelen. Por ejemplo, un MAE de 0.03 equivale aproximadamente a 3 puntos porcentuales de error promedio, una medida comprensible para comparar alternativas desde la perspectiva del inversionista.

Decisión 06 – (27-Sep-2026): Período de cobertura en el dataset

Al revisar `calendar.csv.gz` se observó que las fechas iniciales y finales tenían cobertura parcial, es decir, no aparecían todos los alojamientos durante esos días. Para mantener una población consistente al calcular `occupancy_rate`, se utilizó únicamente el período continuo con cobertura completa: del 03/07/2026 al 23/06/2027. En ese intervalo están presentes los 15,293 listings durante 356 días.

Decisión 07 – (27-Sep-2026): Definición del horizonte de pronóstico

El enunciado solicita pronosticar la ocupación para las próximas semanas, pero no fija un número exacto de días. Se adoptó un horizonte de 28 días, equivalente a cuatro semanas. Este período nos permite evaluar varios ciclos semanales y mantiene el pronóstico dentro de un horizonte de corto plazo útil para comparar barrios.

Decisión 08 – (28-Sep-2026): Construcción de variables de lapso temporal

Para incorporar el comportamiento histórico de cada barrio se construyeron `lag_7`, `lag_14` y `lag_28`. Cada variable representa el valor exacto de `occupancy_rate` del mismo barrio 7, 14 o 28 días antes; no son promedios móviles. Debido a que los primeros 28 días de cada barrio no tienen historia suficiente para calcular los tres rezagos, esas observaciones se excluyeron del conjunto utilizado para modelar.

Decisión 09 – (28-Sep-2026): Esquema de evaluación temporal rolling

Se decidió utilizar una evaluación temporal rolling para simular mejor el uso real del pronóstico. En cada fecha solo se utiliza información disponible anteriormente y, a medida que avanza el tiempo, los valores ya observados pueden alimentar los rezagos. Con esto se respeta el orden cronológico y se evita utilizar información futura para explicar períodos anteriores.

Decisión 10 – (29-Sep-2026): Separación de Development y Test

Los últimos 28 días se reservaron como test final, desde el 27/05/2027 hasta el 23/06/2027, con 1,624 observaciones. Todo lo anterior quedó como Development para entrenamiento y validación. El test permaneció cerrado mientras se seleccionaban variables, configuraciones e hiperparámetros y solo se utilizó después de cerrar las decisiones de modelado.

Decisión 11 – (29-Sep-2026): Validación temporal con tres folds

Dentro de Development se construyeron tres folds temporales. Cada uno utiliza fechas anteriores para entrenar y los siguientes 28 días para validar, aumentando progresivamente el historial disponible. Este esquema se prefirió frente a una partición aleatoria porque representa mejor un escenario de pronóstico y evita entrenar con fechas posteriores a las que se están evaluando.

Decisión 12 – (03-Oct-2026): Selección de XGBoost para el despliegue

En el test final, el baseline estacional lag_7 obtuvo el menor MAE (0.02584), seguido por XGBoost (0.02724) y el MLP (0.033225). Aun reconociendo que lag_7 fue la referencia con menor error, se seleccionó XGBoost como modelo de Machine Learning para la aplicación porque fue el modelo aprendido con mejor desempeño, integra varias características del problema y permite explicar cada predicción mediante SHAP. La diferencia de MAE entre lag_7 y XGBoost fue de 0.00140, aproximadamente 0.14 puntos porcentuales.